

Informe final - Programación Científica

Atención en inteligencia artificial: una explicación visual con triqui

Diego Carvajal González (2) ■ Francisco José Cerén Porto (5) ■ Julián Gustavo Corredor Alfonso (6)

John Smith Ramírez Echeverry (25) ■ Miguel Ángel Rendón Galvis (28)

Universidad Nacional de Colombia, Sede Medellín ■ 5 de agosto de 2026

Resumen. Explicamos la autoatención mediante un experimento pequeño y observable con 958 tableros terminales de triqui. Un mini-Transformer aprende dos tareas: reconstruir una casilla oculta y decidir si X tiene una línea ganadora. Los mapas de calor permiten inspeccionar cómo distribuyen su peso cuatro cabezas de atención. El objetivo no es reproducir una arquitectura grande, sino convertir una idea abstracta en un problema controlado, medible y fácil de comunicar.

Palabras clave: autoatención, Transformer, redes neuronales, visualización, triqui.

1. ¿POR QUÉ ELEGIMOS ESTE TEMA?

Elegimos la atención porque reúne tres elementos centrales de la programación científica: una formulación matemática compacta, una implementación basada en operaciones matriciales y una visualización que ayuda a interpretar resultados. En lugar de presentar el Transformer como una caja negra, quisimos construir una experiencia en la que pudiéramos seguir el recorrido desde los datos hasta la predicción.

El triqui nos pareció adecuado porque sus reglas son conocidas y el tablero tiene solo nueve posiciones. Esto reduce el ruido del problema y permite concentrarnos en la pregunta importante: *cuando falta información, ¿qué relaciones entre casillas utiliza el modelo para recuperarla?* Con el proyecto esperamos mejorar nuestra comprensión de las redes neuronales, del entrenamiento por optimización y de la diferencia entre obtener una predicción correcta y justificarla con evidencia visual.

2. INTERÉS CIENTÍFICO E HISTORIA

Los primeros modelos neuronales de traducción codificaban una secuencia completa en un vector de tamaño fijo. Ese cuello de botella dificultaba conservar información cuando las frases crecían. Bahdanau, Cho y Bengio propusieron aprender una alineación suave: en cada paso, el decodificador asignaba pesos distintos a los estados del codificador y combinaba la información relevante [1]. Luong y colaboradores estudiaron después variantes multiplicativas más simples y eficientes [2].

En 2017, Vaswani y colaboradores presentaron el Transformer, que reemplazó la recurrencia por bloques de autoatención [3]. Esta decisión permitió relacionar directamente posiciones lejanas y paralelizar gran parte del entrenamiento. Su importancia científica no se limita al lenguaje: la misma operación puede aplicarse a conjuntos de mediciones, imágenes, audio o series temporales cuando es necesario combinar información distribuida.

Para una consulta Q , claves K y valores V , la atención de producto punto escalado es

$$\text{Atención}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V. \quad (1)$$

Los productos QK^T miden compatibilidad; *softmax* los convierte en pesos y la suma ponderada de V produce una representación contextual. El factor $\sqrt{d_k}$ evita que productos grandes saturan el *softmax*. Esta ecuación se conecta con el curso porque se implementa con álgebra lineal, se entrena mediante autodiferenciación y se evalúa con experimentos reproducibles.

3. EJEMPLO APLICADO: CASILLAS OCULTAS

3.1. Pregunta y preparación de los datos

Usamos *Tic-Tac-Toe Endgame*, un conjunto de UCI con 958 tableros terminales legales: 626 donde gana X y 332 donde X no gana. La partición estratificada, con semilla fija, dejó 766 tableros para entrenamiento y 192 para validación. Cada tablero se representa como nueve símbolos X/O/vacío y un token adicional

[CLS].

Un único modelo aprende dos tareas. Para la primera se oculta al azar una casilla, que puede contener X, O o estar vacía, y se predice su valor original. Para la segunda se entrega el tablero completo y el vector de [CLS] se usa para decidir si X tiene una línea ganadora. En entrenamiento la posición oculta cambia en cada época; en validación se fija una máscara por tablero para que la comparación sea reproducible.

3.2. Modelo y mapa de atención

El modelo suma embeddings de símbolo y posición, y procesa la secuencia con dos bloques encoder. Cada bloque contiene autoatención de cuatro cabezas, conexiones residuales, normalización y una red interna de dimensión 128; la representación tiene dimensión 32. En total se entrenan 26 020 parámetros durante 150 épocas con Adam y tasa de aprendizaje 3×10^{-3} . Las pérdidas de ambas tareas se suman antes de una única actualización.

Para interpretar un caso extraemos, en la segunda capa, la fila de atención cuya consulta corresponde a la casilla enmascarada. Cada cabeza produce una matriz 3×3 distinta sobre el tablero; un color más claro indica un peso mayor.

3.3. Resultados

Cuadro 1. Desempeño en validación.

Condición	Exactitud	N
Casilla oculta: X/O/vacío	81,8 %	192
Clasificación: ¿gana X?	97,9 %	192

La pérdida conjunta descendió y terminó en 0,344; la parte de casilla oculta fue 0,321 y la de clasificación 0,023. En validación, el modelo acertó el 81,8 % de las casillas ocultas y el 97,9 % de las decisiones sobre si gana X. En el ejemplo de la Fig. 1, la casilla tapada era una O de la fila ganadora: el modelo asignó $p(O) = 0,603$, frente a $p(\text{vacío}) = 0,395$ y $p(X) = 0,002$.

Las cabezas distribuyen el peso de manera diferente; algunas consideran las otras casillas de la fila ganadora, mientras que sus máximos también aparecen fuera de ella. Por tanto, el mapa permite inspeccionar asociaciones internas, pero no demuestra por sí solo la causa de la decisión: distribuciones diferentes pueden producir predicciones similares [4]. Además, los casos visualizados fueron elegidos entre predicciones correctas; la exactitud global de la tabla evita confundir esos ejemplos con todo el desempeño del modelo.




Figura 1. Resultados del notebook. **Izquierda:** pérdidas de entrenamiento para las dos tareas y su suma. **Derecha:** pesos de las cuatro cabezas de la capa 2 al reconstruir la casilla cyan; la línea ganadora real está marcada en verde. El modelo predijo O correctamente con probabilidad 0,603.

4. OPINIÓN DEL GRUPO Y DEL CURSO

Cada integrante aporta una apreciación personal sobre el tema y una evaluación de su aprendizaje o participación en el curso.

Diego Carvajal González

Fue interesante trabajar con arquitecturas de redes neuronales más complejas, en especial explorar una tan importante como el Transformer, aunque sentí que el salto teórico fue grande. Este fue un primer acercamiento valioso al aprendizaje automático y espero usarlo en proyectos futuros. Me autoevalúo con 4,6: intenté profundizar en la mayoría de los temas, aunque la amplitud del curso hizo que algunos se trataran de forma superficial.

Francisco José Cerén Porto

Me parece interesante ver cómo el mecanismo de atención aparece en distintas tareas de procesamiento de información, no solo en lenguaje natural, sino también en imágenes. Los Transformers de visión (ViT) relacionan regiones de una imagen de forma global, algo que las redes convolucionales clásicas no modelan de manera directa. Ante grandes volúmenes de datos, necesitamos algoritmos capaces de encontrar patrones difíciles de reconocer.

Del curso me interesaron especialmente las aproximaciones, el método de Monte Carlo y la explicación de la autodiferenciación. Se abarcaron muchos temas sin volverlos demasiado densos, aunque me habría gustado estudiar más ejemplos reales y discutir su eficiencia computacional. Como autoevaluación, reconozco que podría haberme involucrado más y organizado mejor mi participación.

Julián Gustavo Corredor Alfonso

Me parece valioso que el ejemplo obligue a pasar de una fórmula matricial a un experimento que podamos inspeccionar. El curso me ayudó a entender que programar para ciencia no consiste solo en obtener un resultado: también hay que verificarlo, visualizarlo y comunicarlo. Como autoevaluación, debo seguir mejorando la planificación y la documentación temprana del trabajo en equipo. Al curso le doy 4,5; fue muy interesante y aprendí herramientas que usaré en mi carrera.

John Smith Ramírez Echeverry

Este tema me parece un buen punto de partida para entender la era de la IA, porque los Transformers están detrás de GPT, Claude, Gemini y Llama. La relación entre *query*, *key* y *value* hace el mecanismo más intuitivo y ofrece una forma limitada de inspeccionar el modelo. Al curso le doy 4,5; aprendí bastante, aunque me habría gustado profundizar más en algunas clases.

Miguel Ángel Rendón Galvis

Me resulta llamativo cómo algo tan simple y tangible como el triqui hace que un concepto abstracto se vuelva intuitivo y fácil de visualizar. El curso me abrió la mente frente al potencial de la computación y a la manera de aprovechar la programación sin volverla innecesariamente complicada. También me permitió

descubrir nuevas formas en las que la IA es, y seguirá siendo, parte de nuestras vidas.

Cierre del grupo

En conjunto, consideramos que este proyecto resume bien el espíritu del curso: formular una pregunta concreta, traducirla a datos y operaciones numéricas, comprobar el resultado y presentarlo de forma comprensible. El ejemplo es pequeño, pero nos permite discutir con honestidad tanto la utilidad como los límites de una visualización de atención.

REFERENCIAS

- [1] D. Bahdanau, K. Cho y Y. Bengio, “Neural Machine Translation by Jointly Learning to Align and Translate”, *ICLR*, 2015.
- [2] M.-T. Luong, H. Pham y C. D. Manning, “Effective Approaches to Attention-based Neural Machine Translation”, *EMNLP*, pp. 1412–1421, 2015.
- [3] A. Vaswani et al., “Attention Is All You Need”, *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [4] S. Jain y B. C. Wallace, “Attention is not Explanation”, *NAACL-HLT*, pp. 3543–3556, 2019.