

ANÁLISIS TOPOLÓGICO DE PATOS

PROGRAMACIÓN CIENTÍFICA

Semestre 2026-1

JOAN SEBASTIAN SALAZAR MONTOYA
LAURA GÓMEZ ANGULO

JUAN CAMILO CASTAÑO CHAVARRIAGA
SANTIAGO ABELARDO SALCEDO RODRIGUEZ

RESUMEN. Este proyecto estudia el uso de autoencoders topológicos para conservar la estructura intrínseca de un conjunto de imágenes durante su representación en un espacio latente de menor dimensión. A partir de imágenes de un pato que varían periódicamente en rotación y color, se construye un espacio de parámetros con topología de toro y se comparan un autoencoder convencional ($\lambda = 0$) y uno con pérdida topológica basada en homología persistente ($\lambda = 1$). El experimento permite visualizar cómo la incorporación de información topológica favorece la recuperación de la estructura toroidal esperada.

1. ¿POR QUÉ AUTOENCODERS TOPOLÓGICOS?

Nuestro interés por este tema surgió después de ver una videoconferencia del profesor José Perea sobre la aplicación de la topología al análisis de datos. Aunque ya habíamos estudiado algunos conceptos de topología, nos llamó la atención un ejemplo en el que se analizaba un conjunto de imágenes de un pato de hule tomadas desde diferentes ángulos.




FIGURA 1. Imágenes de un pato de hule tomadas desde diferentes ángulos.

Lo que más nos sorprendió fue que, al comparar las imágenes entre sí y no de manera individual, era posible encontrar relaciones que permitían describir la organización del conjunto completo. Esto nos mostró que la topología no solo se aplica a objetos geométricos, sino que también puede utilizarse para comprender la estructura presente en los datos. Es además útil saber que hasta ahora ya habíamos trabajado en el uso de autoencoders para entender tanto conjuntos de datos como las mismas arquitecturas de redes neuronales usadas, solo que en aspectos distintos al análisis topológico de datos, por lo que encontrar una intersección de estos dos conceptos nos pareció interesante y enriquecedor.

2. SOBRE LA FORMA DE LOS DATOS

Los autoencoders nacieron a mediados de los años ochenta bajo el concepto de redes autoasociativas. Rumelhart, Hinton y Williams plantearon en 1986 las bases de este aprendizaje no supervisado, buscando que la red reconstruyera la salida a la vez que recibía a la entrada. Poco después, entre 1987 y finales de la década, autores como Ballard y LeCun formalizaron el

término para tareas de compresión y reducción no lineal de dimensionalidad.

Décadas más tarde, con el auge del Análisis Topológico de Datos (TDA), surgió el interés por lograr que las redes no solo redujeran la dimensión de los datos, sino que respetaran su conectividad y forma original. Entre 2018 y 2019, trabajos pioneros como los de Hofer, Chen o Brüel-Gabrielsson comenzaron a integrar la homología persistente en redes neuronales. Sin embargo, en esos primeros intentos, la topología funcionaba únicamente como un regularizador aislado: la red intentaba forzar una forma o restricción geométrica fija dentro del espacio latente, pero sin comprobar si esta correspondía a la estructura real de la entrada.

El concepto y la arquitectura del Autoencoder Topológico (TopoAE) como tal se consolidaron entre finales de 2019 (cuando circuló el preprint) y 2020, con la publicación oficial de Michael Moor y su equipo en la conferencia ICML. La diferencia central respecto a los trabajos de 2018 y 2019 fue que Moor introdujo una función de pérdida diferenciable capaz de comparar directamente las firmas topológicas de los datos de entrada con las del espacio latente. En lugar de imponer una estructura artificial a la representación comprimida, este enfoque alinea ambas capas para preservar de forma explícita agrupaciones, bucles y relaciones de cercanía presentes en los datos originales.

En astronomía, los autoencoders topológicos pueden utilizarse para analizar y clasificar los millones de imágenes captadas por telescopios. Al proyectar estas imágenes en un espacio latente de menor dimensión mientras preservan su estructura topológica, permiten agrupar galaxias con características similares, identificar objetos astronómicos inusuales y facilitar el análisis de grandes volúmenes de datos de manera más eficiente.

Además, en medicina, la capacidad de consumir objetos de múltiples dimensiones ha facilitado el análisis de múltiples datos de pacientes a través de la topología. Un caso de éxito viene dado por un estudio donde se usaron grandes cantidades de información de pacientes voluntarios para ser procesada con técnicas de análisis topológico de datos, obteniendo como resultado la identificación exitosa de subgrupos de pacientes con diabetes tipo 2 a través de similitud de genotipos e información médica electrónica [1].

3. UN EJEMPLO APLICADO: PATICOS DE COLORES

A partir de la idea de los patos, explorada en la videoconferencia de José Perea, decidimos ampliar el ejemplo incorporando una segunda variación: además de la rotación del pato, cada imagen cambia de color siguiendo un mapa de colores cíclico (colormap).




FIGURA 2. Variaciones de color de una imagen del pato mediante un mapa de colores cíclico.

Al combinar estos dos cambios periódicos (rotación y color), el conjunto de datos deja de formar únicamente un círculo y pasa a representar una estructura con forma de toro, pues la operación de extender el dataset a través del colormap puede ser concebida teóricamente como el producto cartesiano de dos círculos (uno de rotaciones y otro de coloraciones), cuya topología resultante es la de un toro.

Matemáticamente, si θ representa la rotación y φ la fase de color, el espacio de parámetros satisface

$$S_{\text{rot}}^1 \times S_{\text{color}}^1 \cong T^2. \quad (1)$$

De esta manera, dada la expansión del dataset, se incorpora la implementación de un autoencoder topológico que pueda aprender y preservar la organización intrínseca de estos patos y pueda, así, demostrar de manera práctica el resultado teórico planteado en (1). Para ello se utiliza una arquitectura convolucional que cuenta con un cuello de botella de 3 neuronas, que permite obtener un espacio latente tridimensional y visualizable. Aquí, el aprendizaje se rige por la función de pérdida topológica basada en homología persistente propuesta por Moor et al. en *Topological Autoencoders* [2].

Esta función se construye tomando un pequeño grupo de imágenes, para el que se definen A^X y A^Z como las matrices de distancias por pares en el espacio de datos y en el espacio latente, respectivamente, y π^X y π^Z como los emparejamientos obtenidos mediante homología persistente de dimensión 0. La función de pérdida utilizada es

$$\mathcal{L} = \mathcal{L}_{\text{recon}} + \lambda \mathcal{L}_{\text{topo}}, \quad (2)$$

$$\mathcal{L}_{\text{topo}} = \mathcal{L}_{X \rightarrow Z} + \mathcal{L}_{Z \rightarrow X}, \quad (3)$$

$$\mathcal{L}_{X \rightarrow Z} = \frac{1}{2} \|A^X[\pi^X] - A^Z[\pi^X]\|_2^2, \quad (4)$$

$$\mathcal{L}_{Z \rightarrow X} = \frac{1}{2} \|A^Z[\pi^Z] - A^X[\pi^Z]\|_2^2. \quad (5)$$

Dentro de nuestro ejemplo mostramos la relevancia del uso de esta función de pérdida mediante distintos valores de λ : $\lambda = 0$, que elimina por completo el aporte de la homología, y $\lambda = 1$, que permite incorporar sus resultados.

Tras el entrenamiento de este autoencoder, es posible visualizar cómo en el caso de control ($\lambda = 0$), aunque se vislumbra algo de estructura toroidal, la imagen parece envuelta en sí misma, mientras que en el entrenamiento topológico ($\lambda = 1$), la estructura del toro es clara, como se observa en la Figura 3.

Este resultado da claridad en la relevancia del uso de estas técnicas para el estudio de la geometría de estos problemas, sin necesidad de tener que usar herramientas de reducción de dimensionalidad para interpretar los datos.

Como continuación de este trabajo, sería posible extender el experimento a conjuntos de imágenes generados por espacios de parámetros más complejos, incluyendo superficies como la botella de Klein o el plano proyectivo. También se podrían estudiar arquitecturas con espacios latentes de mayor dimensión, incorporar características de homología persistente en dimensiones superiores y evaluar cuantitativamente qué tan bien se conserva la topología frente al ruido o a datos incompletos. Finalmente, aplicar esta metodología a colecciones reales de imágenes permitiría explorar su utilidad en tareas de clasificación, detección de anomalías y descubrimiento de estructuras que no sean conocidas de antemano.




FIGURA 3. Comparación de los espacios latentes tridimensionales. Izquierda: modelo de control con $\lambda = 0$. Derecha: modelo topológico con $\lambda = 1$. En ambos casos, el color representa el ángulo de rotación del pato; la escala se muestra en la gráfica derecha.

4. OPINIÓN

Joan Sebastian Salazar Montoya: En cuanto al trabajo, pienso que es apenas la punta del iceberg de un esfuerzo por entender la topología desde las imágenes. Esto permite acercarse a la topología de superficies difíciles de visualizar (como la botella de Klein o el plano proyectivo) a través de una forma más accesible y tangible. Más aún, este trabajo muestra que no es necesario realizar una proyección UMAP de la capa de cuello de botella, sino que un autoencoder con *loss* topológico ya permite capturar la topología de un conjunto de imágenes. Ahora, con respecto al curso, fue muy útil la parte de visualización. Los consejos y lineamientos de cómo hacer gráficas nunca los olvidaré (we all hate Jet). Por otro lado, la parte de modelamiento y sistemas dinámicos me dio muchas ganas de estudiar más. Eché en falta al menos una clase sobre la transformada de Fourier (que, si bien estaba en una tarea, hubiera sido interesante discutirla). Creo que una sesión enfocada solamente en cómo hacer *prompts* y, en general, en usar la IA para generar código hubiera sido interesante. Lo cierto es que el enfoque que se le dio al curso fue muy bueno; ojalá siga así.

Juan Camilo Castaño Chavarriaga: La primera vez que escuché la relación entre la topología y las redes neuronales me quedé loco. Son especialmente increíbles para mí los resultados de nuestro ejemplo, pues revelan de manera tangible un resultado abstracto (pues en general, la topología siempre luce extraña y abstracta), como lo es el que el producto cartesiano de dos círculos sea un toro.

En general, este curso resultó para mí muy enriquecedor a la hora de mostrar el sentido práctico de muchas cosas hasta ahora intangibles para mí, y además me hizo caer en la cuenta de cosas

importantes a las que antes no les daba tanta relevancia (¡como la visualización científica!).

Laura Gómez Angulo: El tema de los autoencoders topológicos me pareció muy interesante, ya que antes de este trabajo no conocía sus aplicaciones. Investigar sobre él me permitió comprender cómo la topología puede utilizarse para reducir la dimensionalidad de los datos sin perder su estructura. Además, el ejemplo del pato mostró de forma sencilla un concepto que puede extenderse a problemas mucho más complejos. Este curso amplió mi perspectiva sobre las matemáticas y la programación, mostrándome cómo pasar de una situación tangible a una función matemática y, por último, a un código.

Santiago Abelardo Salcedo Rodríguez: Es chévere conseguir conexiones en temas que parecen tan aparentemente alejados; es una gran virtud poder estudiar estas relaciones tan raras que surgen en las matemáticas. Sobre la materia, considero que logró mostrarme lo importante que es tener buenas prácticas para un trabajo en equipo más ameno, lograr transmitir de mejor forma las ideas con la visualización adecuada, y 100 % me será útil para el resto de mi vida.

REFERENCIAS

- [1] L. Li et al., “Identification of type 2 diabetes subgroups through topological analysis of patient similarity”, *Science Translational Medicine*, vol. 7, no. 311, 311ra174, 2015. doi:10.1126/scitranslmed.aaa9364.
- [2] M. Moor, M. Horn, B. Rieck y K. Borgwardt, “Topological Autoencoders”, en *Proceedings of the 37th International Conference on Machine Learning*, PMLR, vol. 119, pp. 7045–7054, 2020. arXiv:1906.00722.