

¿POR QUÉ ELIGIERON ESTE TEMA?

En general, el tema de las PINNs despertó interés porque permitió relacionar las ecuaciones diferenciales con aplicaciones reales en la física y conocer una forma innovadora de resolver estos problemas mediante redes neuronales. Además, se valoró la integración entre matemáticas, física e inteligencia artificial, así como la posibilidad de aplicar estos conocimientos en áreas como la simulación y la ingeniería. Para varios integrantes, fue un tema completamente nuevo que despertó la curiosidad y el interés por seguir profundizando en este campo.

¿POR QUÉ ES INTERESANTE EN LA CIENCIA?

- contexto histórico:

La idea de las Redes Neuronales Informadas por la Física (PINNs) surge de la necesidad de resolver ecuaciones diferenciales aprovechando la capacidad de las redes neuronales como aproximadores universales de funciones. Aunque el término se ha popularizado recientemente, su desarrollo tiene dos etapas clave marcadas por diferentes autores:

Los pioneros (1998)

La primera propuesta formal de utilizar redes neuronales para resolver ecuaciones diferenciales ordinarias (EDOs) y parciales (EDPs) apareció en un artículo de 1998 escrito por I.E. Lagaris, A. Likas y D.I. Fotiadis

En esta versión inicial, el enfoque era ligeramente distinto al actual:

- Se proponía una función de test que separaba la condición inicial de la ecuación diferencial.
- La solución se construía de tal forma que cumpliera las condiciones de contorno por construcción, lo que dificulta su aplicación en dominios con geometrías complejas o difíciles de generalizar

El desarrollo moderno (2017-2019)

La versión de las PINNs que se utiliza hoy en día y que permitió su "boom" actual fue desarrollada principalmente por Maziar Raissi, Paris Perdikaris y George Em Karniadakis. Su gran innovación respecto al modelo de 1998 fue:

- **Generalización:** Integraron las condiciones de contorno e iniciales directamente en la función de pérdida (loss) de la red.
- **Diferenciación automática:** Utilizaron el cálculo en grafos computacionales (backpropagation) para obtener las derivadas exactas de la red respecto a sus entradas, permitiendo que la red aprenda a minimizar el residuo de la ecuación física de forma eficiente.
- **Nuevas aplicaciones:** No solo se enfocaron en resolver ecuaciones (problemas directos), sino también en el descubrimiento de leyes físicas (problemas inversos) a partir de datos dispersos y ruidosos

- ¿por qué es relevante?


Las ecuaciones diferenciales parciales son el instrumento utilizado para modelar los fenómenos físicos, así se puede describir como cambian determinadas cantidades en el

espacio y el tiempo, favoreciendo la comprensión de problemas esenciales en la ciencia e ingeniería.

La complejidad de estas ecuaciones hace que sea difícil y a menudo imposible encontrar soluciones exactas, lo que destaca la necesidad de métodos numéricos a la altura de aproximar las soluciones.

En este orden de ideas las redes neuronales han demostrado ser un recurso útil que vale la pena desarrollar para aproximar funciones continuas con gran precisión.

Las Physics-Informed Neural Networks (PINNs) son un tipo de redes neuronales que adscriben las leyes de la física expresadas en EDP en su proceso de aprendizaje. Consiste en imponer las EDP en la función de pérdida como una restricción, permitiendo a las redes aprender soluciones dentro de los límites de las leyes físicas implementadas.



El **Teorema de Aproximación Universal** es el fundamento teórico que permite a las PINNs actuar como aproximadores de soluciones para ecuaciones diferenciales

El teorema establece que una red neuronal con al menos una capa oculta y una función de activación no constante (como la sigmoide, tanh o elu) puede aproximar cualquier función continua con una precisión arbitraria en un dominio cerrado y acotado. En las PINNs, se aprovecha esta propiedad para proponer que la solución oculta de una ecuación diferencial, denominada $u(t, x)$, sea aproximada por una red neuronal profunda

Dado que el teorema garantiza que la red puede representar la función solución, el desafío de las PINNs es "forzar" a ese aproximador universal a respetar las leyes de la física. Para ello, se realizan los siguientes pasos:

- **Derivación Automática:** Se utiliza la estructura de la red neuronal para calcular las derivadas de la salida respecto a las entradas (espacio y tiempo) mediante algoritmos como la retropropagación.
- **Codificación de la Ecuación:** Estas derivadas se insertan en la estructura de la ecuación diferencial (el residuo físico).
- **Optimización de Parámetros:** En lugar de aprender solo de datos etiquetados, la red ajusta sus pesos y sesgos para **minimizar una función de pérdida** que incluye el incumplimiento de la ecuación física y las condiciones de contorno

Las PINNs han sido muy relevantes en la ciencia, pues Su aplicación es vasta y abarca problemas cruciales de ingeniería y ciencias aplicadas:

- Mecánica de fluidos, mecánica cuántica, sistemas dinámicos y otras áreas.


EJEMPLO APLICADO.

Queremos resolver la siguiente ecuación

$$\begin{aligned}\nabla^2 u(x, y) &= f(x, y) \quad \forall (x, y) \in \Omega \\ u(x, y) &= 0 \quad \forall (x, y) \in \partial\Omega\end{aligned}$$

En el ejemplo tendremos $\Omega = (0, 1)^2$.

En nuestro ejemplo, buscamos solucionar la EDP (ecuación de Poisson, la cual puede describir electrostática, Gravitometría, Termodinámica y Fluidos Termodinámica y Fluidos) mediante PINNs. Inicialmente generamos nuestros puntos de muestra de tal manera que su distribución no se acumule en una zona específica del dominio (esto causaría que no veríamos la solución por completo). Tras esto entrenamos nuestra red neuronal siguiendo las ideas del Teorema de aproximación universal y teniendo en cuenta las condiciones de frontera y las condiciones iniciales dadas por la EDP. Posteriormente entrenamos nuestra red hasta que alcance un error aceptable, finalmente comparamos la solución dada con la solución real y a su vez observamos como se comporta el error en todo el dominio.



OPINIÓN DEL GRUPO

Alexa: El tema me pareció interesante porque, aunque es complejo y requiere dedicación, tiene aplicaciones reales en la física. Además, fue mi primer acercamiento al análisis numérico y las redes neuronales, despertando mi interés por seguir aprendiendo.

Yuliana: Me pareció un tema muy interesante, ya que conocí por primera vez cómo las redes neuronales pueden utilizarse para resolver ecuaciones diferenciales. Además, aprender Python y GitHub hizo del curso una experiencia muy enriquecedora.

Ana: Considero que las PINNs son una herramienta muy útil para la física y la ingeniería, al integrar las leyes físicas en el aprendizaje de las redes neuronales. El curso también me permitió fortalecer mis conocimientos en programación y comprender la importancia de GitHub.

Samuel: El tema me llamó la atención porque integra redes neuronales, aproximación de funciones y ecuaciones diferenciales, áreas que disfruto dentro de la matemática aplicada. Además, considero que el curso fue una excelente introducción a la programación científica y a nuevas herramientas de aprendizaje.

Shara: Las PINNs a diferencia de los métodos numéricos que dependen de mallas complejas, usan el Teorema de Aproximación Universal para aprender la solución sin necesitar una malla perfecta. Desarrollar este ejercicio me permitió entender cómo funciona realmente una red neuronal y cómo podemos entrenarla para resolver problemas físicos